Inteligência Artificial Aplicada à Previsão de Demanda em Sistemas de Produção Puxada: Um Estudo em uma Empresa de Sucos

Thálys Correa[1], Cristine Schwanke[2], Isadora Camargo[3], Sandro Camargo[1]

[1]Engenharia da Computação – Universidade Federal do Pampa

[2]Engenharia de Energia – Universidade Federal do Pampa

[3]Engenharia de Produção – Universidade Federal do Pampa
Caixa Postal 118 – 96.413-172 – Bagé – RS – Brazil

Abstract. *Este trabalho avalia a aplicação de modelos de aprendizado de máquina para a previsão de demanda mensal em uma empresa de sucos naturais operando sob sistema de produção puxada. Foram comparados um modelo de regressão linear múltipla e uma rede neural recorrente do tipo LSTM, treinados sobre uma base de dados mensal de 15 sabores comercializados entre abril de 2025 e junho de 2026. Os resultados, avaliados por coeficiente de determinação (R^2) tanto de forma agregada quanto individualizada por sabor, indicam que a regressão linear apresenta desempenho mais estável do que a LSTM na maioria dos sabores analisados, sobretudo quando a avaliação agregada — que tende a mascarar falhas de ajuste em sabores de menor volume — é substituída por uma avaliação desagregada. A partir dos resultados, propõe-se uma estratégia de gestão de estoque baseada em três cenários de risco (conservador, de equilíbrio e otimista), fundamentada no erro histórico de previsão obtido por validação cruzada. O estudo discute ainda os desafios impostos por uma base de dados de tamanho reduzido e por sabores de lançamento recente, oferecendo subsídios práticos para o planejamento produtivo da empresa estudada.*
Palavras-chave: *previsão de demanda; aprendizado de máquina; regressão linear; LSTM; produção puxada; gestão de estoque.*

1. Introdução

A crescente competitividade do setor de alimentos e bebidas exige que as empresas aprimorem continuamente seus processos produtivos para reduzir custos, aumentar a qualidade dos produtos e responder de forma ágil às oscilações do mercado. Nesse contexto, a compreensão dos fatores que influenciam a eficiência da produção tornam-se fundamental para o desenvolvimento de estratégias que conciliem competitividade, qualidade e rentabilidade [Rocha et al. 2024]. Entre essas estratégias, destaca-se a produção puxada, princípio da manufatura enxuta no qual a produção é orientada pela demanda do cliente, permitindo maior flexibilidade operacional e adaptação às variações do mercado [Tošanović and Štefanić 2021].

Em empresas produtoras de sucos naturais, a elevada variabilidade da demanda representa um desafio para o planejamento da produção. Como o sistema produtivo é baseado na produção puxada, imprecisões nas estimativas de vendas afetam diretamente o dimensionamento dos estoques, a aquisição de insumos e a utilização da capacidade

produtiva. Além disso, a perecibilidade das matérias-primas torna o excesso de estoque custoso, enquanto previsões subestimadas podem ocasionar rupturas no abastecimento e perda de vendas [Dandaro and Martello 2015].

Nesse cenário, técnicas de Inteligência Artificial (IA) têm se consolidado como ferramentas promissoras para apoiar a tomada de decisão. A partir de dados históricos de vendas e de variáveis explicativas, como sazonalidade, calendário e fatores externos, modelos preditivos são capazes de identificar padrões de comportamento da demanda e gerar estimativas mais precisas para o planejamento operacional [Douaioui et al. 2024]. Além de reduzir a dependência de estimativas subjetivas, esses modelos podem ser continuamente atualizados com novos dados, adaptando-se às mudanças no comportamento dos consumidores.

Entre as abordagens utilizadas para previsão de demanda, a regressão linear destaca-se pela simplicidade, interpretabilidade e eficiência na modelagem de relações lineares entre variáveis [Montgomery et al. 2021]. Em contrapartida, modelos de aprendizado profundo, como redes neurais recorrentes do tipo *Long Short-Term Memory* (LSTM), apresentam maior capacidade para representar relações não lineares e dependências temporais complexas, características frequentemente presentes em séries históricas de vendas [James et al. 2023]. Dessa forma, a comparação entre essas abordagens possibilita avaliar o equilíbrio entre simplicidade, interpretabilidade e capacidade preditiva em diferentes contextos.

Diante desse contexto, este trabalho tem como objetivo desenvolver e comparar modelos de previsão de demanda para estimar o volume de vendas do mês subsequente em uma empresa de sucos naturais. Para isso, são utilizados dados históricos de vendas para a construção e avaliação de modelos baseados em regressão linear e redes neurais LSTM. Espera-se que os resultados obtidos contribuam para o planejamento da produção, reduzindo desperdícios, otimizando a alocação de recursos e fornecendo suporte à tomada de decisão baseada em dados.

1.1. Trabalhos Relacionados

A previsão de demanda por meio de aprendizado de máquina tem sido amplamente investigada, principalmente por meio da comparação entre modelos estatísticos tradicionais e arquiteturas de aprendizado profundo. Entre estas, as redes neurais LSTM destacam-se por sua capacidade de capturar dependências temporais de longo prazo e padrões sazonais complexos, frequentemente superando modelos lineares em cenários com elevada variabilidade temporal [Douaioui et al. 2024, Veres and Baráth 2024]. Entretanto, essa superioridade não é universal. [Veres and Baráth 2024] ressaltam que o desempenho de modelos mais complexos depende das características dos dados e do contexto de aplicação. De forma semelhante, [Golabek et al. 2020], ao compararem diferentes modelos para previsão de demanda de produtos de consumo rápido, observaram que, na categoria de bebidas, algoritmos mais simples, como Regressão Linear e *Random Forest*, alcançaram desempenho equivalente ou superior ao das LSTMs.

Outro desafio recorrente na literatura refere-se à limitação dos dados históricos disponíveis. Em cenários caracterizados por séries temporais curtas ou intermitentes, modelos convencionais podem apresentar desempenho insatisfatório. Nesse contexto, [Rožanec and Mladenic 2021] propuseram uma abordagem que separa a previsão da

ocorrência da demanda da previsão de sua magnitude, além de destacarem a importância da utilização de métricas de avaliação adequadas para evitar interpretações equivocadas dos resultados.

Este trabalho insere-se nesse contexto ao investigar a previsão de demanda em uma pequena empresa do setor de bebidas naturais, caracterizada por histórico de vendas limitado e diferenças expressivas de volume entre os sabores comercializados. Especificamente, o estudo compara o desempenho da regressão linear e da LSTM em um cenário de baixa disponibilidade de dados, analisa a influência do volume de informações históricas na qualidade das previsões e discute uma limitação metodológica pouco explorada na literatura, relacionada à interpretação de métricas agregadas de desempenho quando aplicadas a produtos com escalas de vendas heterogêneas. Nesse caso, demonstra-se que métricas globais podem mascarar o desempenho preditivo em sabores individuais, evidenciando a necessidade de avaliações complementares por grupo de produtos.

2. Materiais e Métodos

Este estudo adota uma abordagem quantitativa aplicada, baseada em experimentação computacional para a avaliação de modelos de previsão de demanda. Foram implementados dois modelos preditivos, sendo uma regressão linear múltipla ajustada pelo método dos mínimos quadrados ordinários (*Ordinary Least Squares* (OLS) e uma rede neural recorrente do tipo *Long Short-Term Memory* (LSTM). O desempenho dessas abordagens foi comparado na previsão do volume mensal de vendas por sabor. Todos códigos foram executados no ambiente Google Colab, utilizando a linguagem Python.

2.1. Base de Dados

A base de dados foi fornecida pela empresa Claújuices, especializada na produção de sucos naturais, e abrange o período de abril de 2025 a junho de 2026, totalizando 15 meses consecutivos. Originalmente, o conjunto continha apenas registros de meses em que houve comercialização de determinado sabor. Durante o pré-processamento, a base foi expandida para incluir todas as combinações entre os 15 sabores e os 15 meses analisados, resultando em um painel de 225 registros. As combinações sem vendas foram preenchidas com volume igual a zero, representando ausência efetiva de comercialização e não valores ausentes. Cada registro corresponde ao volume vendido, em litros, de um sabor em um mês específico. Aproximadamente 53% das observações apresentam volume igual a zero, refletindo a diferença entre sabores consolidados e produtos recém-lançados ou de baixa demanda. Cada registro é descrito pelas seguintes variáveis:

- Ano e mês de referência;
- Sabor do produto (codificado numericamente);
- Temperatura média mensal;
- Número de dias úteis e de finais de semana;
- Indicador de ocorrência de feriados;
- Indicador binário de sabor recém-lançado;
- Volume vendido no mês anterior;
- Média móvel de três meses do volume vendido;
- Volume vendido no mês corrente (variável-alvo).

A variável correspondente ao mês foi codificada de forma cíclica por meio das funções seno e cosseno, preservando a continuidade temporal entre dezembro e janeiro. Devido à heterogeneidade do histórico de vendas, os experimentos principais foram restritos aos sabores com pelo menos seis meses de vendas não nulas, classificados como sabores estabelecidos. Assim, o estudo contemplou os sabores abacaxi, abacaxi com hortelã, bergamota, laranja, laranja com couve, limonada, maracujá, morango e uva. Os sabores butiá, goiaba, manga, melancia e pink lemonade, por apresentarem quantidade insuficiente de observações para o treinamento de modelos específicos, foram analisados separadamente por meio de estimativas de referência baseadas na média histórica. As implicações dessa limitação são discutidas na Seção 4.

As variáveis explicativas foram normalizadas por meio da técnica *Min-Max*, utilizando parâmetros estimados exclusivamente a partir do conjunto de treinamento, posteriormente aplicados ao conjunto de teste para evitar vazamento de informação. A variável-alvo foi normalizada individualmente para cada sabor, devido às diferenças expressivas de escala entre os volumes de venda.

A divisão entre treinamento e teste foi adaptada às características de cada modelo. Na regressão linear, empregou-se uma divisão aleatória estratificada por sabor, mantendo aproximadamente 80% das observações para treinamento e 20% para teste em cada grupo. Para a LSTM, a divisão foi cronológica, reservando os três meses mais recentes para teste e utilizando os meses anteriores para treinamento, preservando a sequência temporal dos dados.

2.2. Modelos e Métricas de Avaliação

O primeiro modelo consiste em uma regressão linear múltipla ajustada pelo método dos mínimos quadrados ordinários (OLS), utilizando a implementação *LinearRegression* da biblioteca *scikit-learn*. Em vez de modelos independentes para cada sabor, foi ajustado um único modelo utilizando o identificador do sabor como variável explicativa numérica. Essa estratégia foi adotada por conta da pequena quantidade de instâncias por sabor que comprometia a estabilidade estatística de modelos individuais. Como a regressão linear possui solução analítica, não há hiperparâmetros de treinamento iterativo, como número de épocas ou taxa de aprendizado. O segundo modelo consiste em uma rede neural recorrente do tipo LSTM, empregada para modelar as dependências temporais da série histórica de vendas. A arquitetura é composta por uma camada LSTM com 16 unidades e ativação tangente hiperbólica, seguida por uma camada com oito neurônios e ativação ReLU e uma camada de saída com um único neurônio responsável pela previsão do volume vendido no mês subsequente.

A entrada do modelo é formada por sequências temporais de três meses consecutivos (*lookback* = 3), compostas pelas variáveis explicativas e pelo histórico de vendas incorporado à própria sequência. As variáveis defasadas utilizadas na regressão linear (volume do mês anterior e média móvel de três meses) não foram incluídas, pois a LSTM é capaz de aprender automaticamente essas dependências temporais durante o treinamento.

O modelo foi treinado durante 200 épocas utilizando o otimizador Adam, com taxa de aprendizado igual a 0,001 e função de perda baseada no erro quadrático médio (MSE). Durante o treinamento, 15% das amostras foram reservadas para validação interna.

O desempenho dos modelos foi avaliado por meio do coeficiente de determinação (R^2), definido por:

$$R^2 = 1 - \frac{SQ_{res}}{SQ_{tot}},$$

em que SQ_{res} representa a soma dos quadrados dos resíduos e SQ_{tot} a soma dos quadrados totais em torno da média dos valores observados. Quando calculado sobre um conjunto de teste independente, o R^2 pode assumir valores negativos, indicando desempenho inferior ao obtido pela previsão baseada na média dos dados de treinamento.

Foram calculados dois indicadores: o R^2 global, obtido a partir das previsões conjuntas de todos os sabores, e o R^2 por sabor. Essa distinção é necessária porque as diferenças de escala entre os volumes vendidos podem inflar artificialmente o desempenho global, refletindo principalmente a capacidade do modelo de distinguir sabores de alta e baixa demanda, sem necessariamente representar adequadamente a dinâmica temporal de cada sabor. Assim, o R^2 por sabor foi adotado como principal métrica de avaliação, enquanto o R^2 global foi utilizado apenas como medida complementar.

O R^2 individual não foi calculado para sabores com menos de duas observações no conjunto de teste, uma vez que essa quantidade é insuficiente para estimar de forma confiável a variância explicada pelo modelo.

3. Resultados e Discussões

Os modelos foram avaliados utilizando os nove sabores classificados como estabelecidos (Seção 2.1). Na regressão linear, foram utilizadas 108 instâncias para treinamento e 27 para teste. Para a LSTM, empregaram-se 81 sequências de treinamento e 27 de teste, em decorrência da utilização de janelas temporais de três meses (*lookback* = 3).

3.1. Regressão Linear

A Tabela 1 apresenta os valores de R^2 obtidos pela regressão linear para cada sabor nos conjuntos de treinamento e teste.

Tabela 1. Regressão Linear - R² por sabor

ID	Sabor	R² (Treino, N = 12)	R² (Teste, N = 3)
1	Abacaxi	0,232	-7,271
2	Abacaxi com Hortelã	0,228	-0,007
3	Bergamota	-0,020	-0,371
6	Laranja	0,470	-15,952
7	Laranja e Couve	0,066	-2,410
9	Limonada	0,422	0,590
10	Maracujá	-0,021	-7,111
13	Morango	0,410	0,405
15	Uva	-0,066	0,150
	Global	0,921	**0,897**

Apesar do elevado valor de R^2 global obtido no conjunto de teste (0,897), sua interpretação requer cautela, pois a métrica é sensível às diferenças de escala existentes entre os sabores avaliados. Considerando o R^2 por sabor, adotado como principal métrica de avaliação, observa-se desempenho heterogêneo. Os sabores Limonada ($R^2 = 0,590$), Morango ($R^2 = 0,405$) e Uva ($R^2 = 0,150$) apresentaram desempenho satisfatório, enquanto Abacaxi, Laranja e Maracujá obtiveram valores negativos. O pior resultado foi observado para o sabor Laranja ($R^2 = -15,952$). Apesar da correção de inconsistências identificadas na base de dados, a elevada variabilidade da série histórica desse sabor (coeficiente de variação de 26,5%) e o reduzido número de observações no conjunto de teste contribuíram para a instabilidade do coeficiente de determinação.

A análise dos coeficientes do modelo indica que as variáveis temperatura ($+0,21$) e mês de referência ($+0,28$, na representação cíclica) estão positivamente associadas ao volume de vendas, corroborando a influência da sazonalidade discutida na Seção 1. As variáveis autorregressivas volume do mês anterior ($+1,43$) e média móvel de três meses ($-0,68$) apresentaram sinais opostos, comportamento compatível com a elevada correlação entre ambas e característico de multicolinearidade. Por fim, o coeficiente associado ao identificador do sabor ($-0,05$) apresentou baixa magnitude, resultado esperado devido à representação numérica adotada para uma variável originalmente categórica.

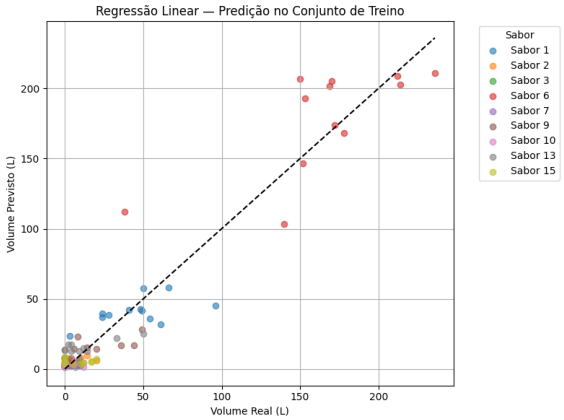


Figura 1. Predições no conjunto de treinamento de OLS. Fonte: Autores (2026)

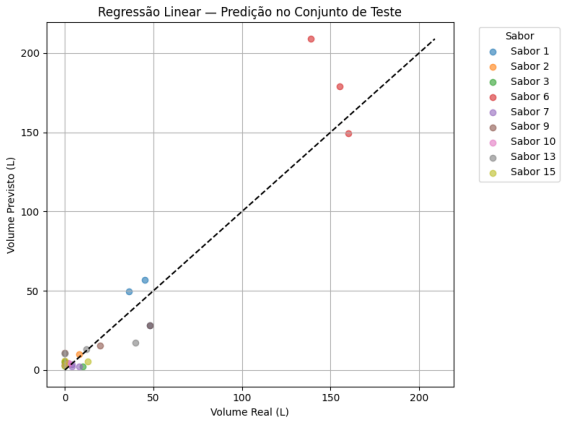


Figura 2. Predições no conjunto de teste de OLS. Fonte: Autores (2026)

As Figuras 1 e 2 ilustram a dispersão entre os valores previstos e observados nos conjuntos de treinamento e teste, respectivamente. Observa-se maior concentração de pontos próximos à linha de identidade nos sabores de menor volume, enquanto os sabores de maior escala exibem maior dispersão em torno dessa linha, refletindo a variabilidade absoluta mais elevada desses produtos.

3.2. LSTM

Tabela 2. LSTM - R² por sabor

ID	Sabor	R² (Treino, N = 9)	R² (Teste, N = 3)
1	Abacaxi	-0,488	-0,125
2	Abacaxi com Hortelã	-0,319	-0,366
3	Bergamota	-2,294	-0,500
6	Laranja	-0,110	-42,985
7	Laranja e Couve	-1,272	-0,962
9	Limonada	0,349	0,713
10	Maracujá	-3,321	-0,635
13	Morango	0,015	-1,755
15	Uva	-0,618	-0,277
	Global	0,927	**0,975**

A Tabela 2 apresenta os resultados obtidos pela rede LSTM. Assim como na regressão linear, o R^2 global permaneceu elevado (0,975 no conjunto de teste), enquanto a avaliação individual por sabor revelou desempenho significativamente inferior. Com exceção da Limonada, que apresentou R^2 positivo tanto no treinamento (0,349) quanto no teste (0,713), todos os demais sabores obtiveram desempenho negativo no conjunto de teste. Esse foi também o único caso em que a LSTM superou a regressão linear.

O sabor Laranja apresentou novamente o menor desempenho ($R^2 = -42,985$), indicando que a arquitetura recorrente não foi capaz de modelar adequadamente sua elevada variabilidade com apenas nove sequências de treinamento.

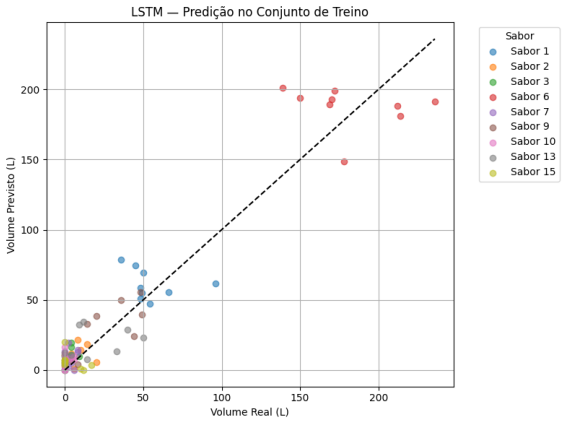


Figura 3. Correlação do modelo de treino de LSTM. Fonte: Autores (2026)

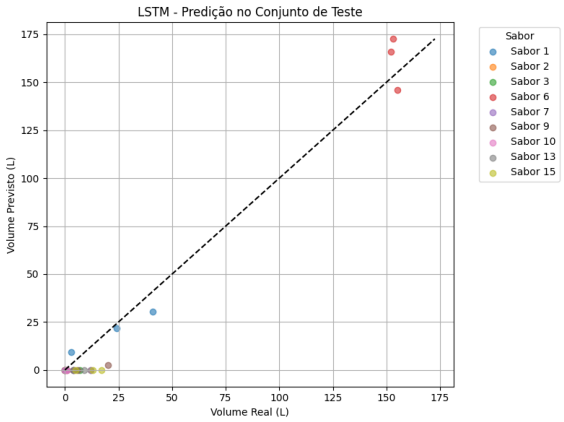


Figura 4. Correlação do modelo de teste de LSTM. Fonte: Autores (2026)

As Figuras 3 e 4 apresentam os resultados obtidos para o modelo LSTM. Em comparação com a regressão linear, apresentados nas Figuras 1 e 2, observa-se maior dispersão entre os valores previstos e observados, especialmente no conjunto de teste, comportamento compatível com os valores de R^2 predominantemente negativos apresentados na Tabela 2.

A Figura 5 apresenta a evolução do erro quadrático médio (MSE) ao longo das 200 épocas de treinamento do modelo LSTM, para os conjuntos de treinamento e de validação interna. Observa-se redução acentuada do erro nas primeiras 25 épocas, seguida de convergência gradual até a estabilização, a partir de aproximadamente 75 épocas, em um patamar próximo de zero em escala normalizada. A curva de validação estabiliza-se em valores ligeiramente inferiores à curva de treinamento ao longo da maior parte do processo, sem indícios de divergência crescente entre as duas curvas o que descarta sobreajuste (*overfitting*) progressivo como explicação para o baixo desempenho da LSTM no conjunto de teste, reforçando a interpretação já discutida na Seção 3.1 de que a limitação decorre predominantemente do volume insuficiente de dados por sabor, e não de treinamento excessivo.

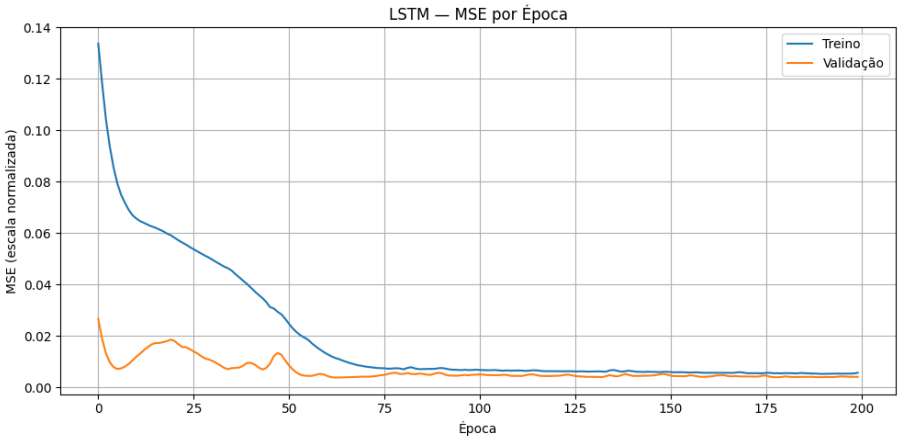


Figura 5. Gráfico de MSE do modelo de LSTM. Fonte: Autores (2026)

3.3. Comparação entre os modelos

Considerando o R^2 por sabor no conjunto de teste, a regressão linear apresentou desempenho superior ao da LSTM em oito dos nove sabores avaliados, sendo superada apenas para o sabor Limonada. De modo geral, a regressão linear produziu previsões mais próximas da variabilidade observada nos dados, enquanto a LSTM apresentou erros de maior magnitude, especialmente para sabores com maior variabilidade temporal.

Esse resultado está de acordo com a literatura, que indica que arquiteturas de aprendizado profundo tendem a demandar maior volume de dados para superar modelos estatísticos tradicionais [Veres and Baráth 2024]. No presente estudo, cada sabor estabelecido dispõe de apenas nove a doze observações mensais para treinamento, quantidade insuficiente para explorar adequadamente a capacidade de generalização da LSTM. Nessas condições, a regressão linear mostrou-se mais robusta e consistente.

As Figuras 6 e 7 complementam essa análise ao apresentarem, respectivamente, a evolução temporal e a distribuição estatística do volume de vendas dos sabores estabelecidos. A Figura 6 mostra que o sabor Laranja apresenta o maior volume médio de vendas, acompanhado de elevada variabilidade temporal, com oscilações entre valores próximos de 140 L e superiores a 200 L. Esse comportamento é confirmado pela Figura 7, na qual o sabor Laranja exibe a maior amplitude interquartil e dispersão, embora mantenha mediana superior à dos demais sabores. Em contraste, sabores de menor volume, como Bergamota, Maracuja e Laranja e Couve, apresentam baixa variabilidade absoluta e valores concentrados próximos de zero, ainda que ocorram outliers associados a períodos específicos de maior demanda, como o pico observado para o sabor Abacaxi em agosto de 2025 (Figura 6). A elevada variabilidade absoluta do sabor Laranja contribui para explicar seus menores valores de R², tanto na regressão linear quanto na LSTM (Tabelas 1 e 2), uma vez que erros absolutos de previsão tendem a ser maiores em séries de maior magnitude, reduzindo o coeficiente de determinação, especialmente em conjuntos de teste de tamanho limitado.

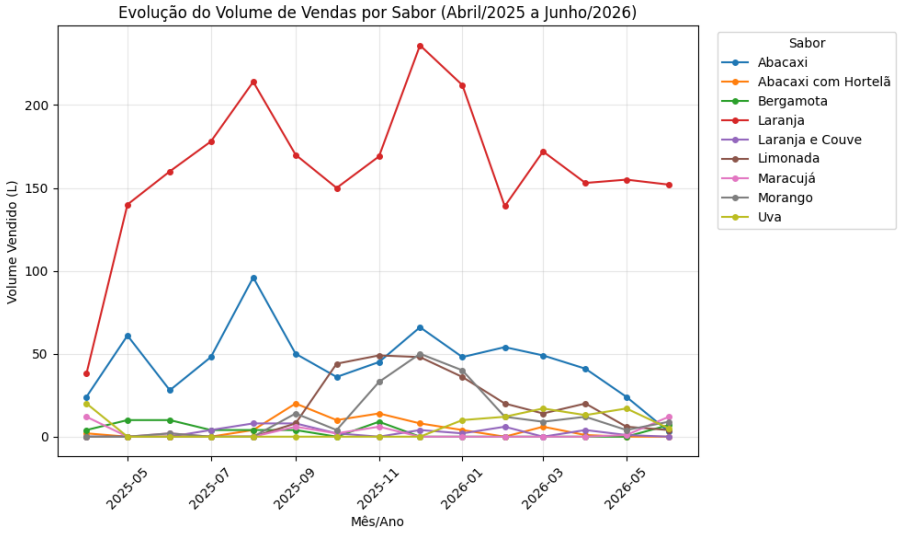


Figura 6. Gráfico de linhas de volume de vendas. Fonte: Autores (2026)

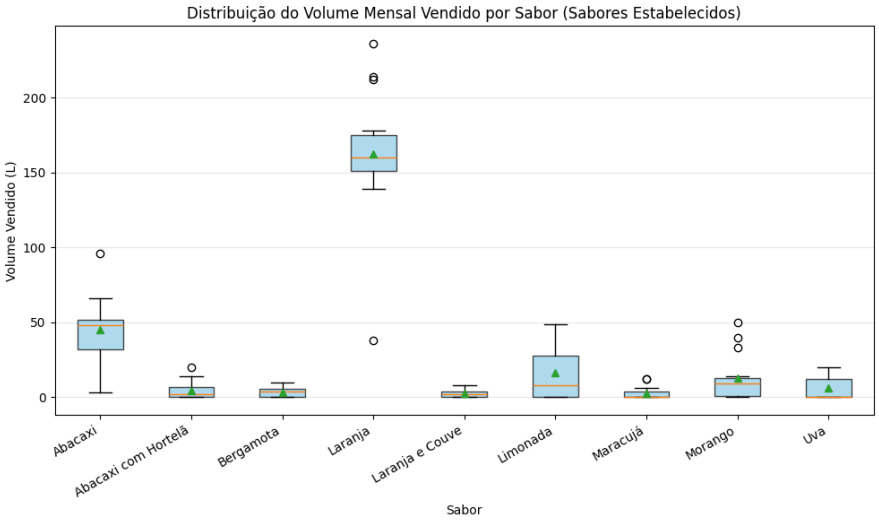


Figura 7. Gráfico de caixa de volume de vendas. Fonte: Autores (2026)

3.4. Previsão para Junho de 2026

Para avaliar a aplicação prática dos modelos, ambos foram retreinados utilizando todas as observações disponíveis até maio de 2026, reservando junho de 2026 como conjunto de validação prospectiva (*holdout*). A Tabela 3 apresenta as previsões obtidas.

Tabela 3. Previsões para junho de 2026: valores reais vs. modelos

Sabor	Real (L)	Regressão Linear (L)	LSTM (L)
Abacaxi	3,0	32,8	13,4
Abacaxi com Hortelã	0,0	1,4	0,0
Bergamota	7,0	0,7	0,0
Laranja	152,0	152,7	154,3
Laranja e Couve	0,0	0,5	0,0
Limonada	4,0	2,6	0,0
Maracujá	12,0	0,7	0,0
Morango	9,0	2,1	0,0
Uva	5,0	1,9	1,3

Os dois modelos apresentaram elevada precisão para o sabor Laranja, com previsões de 152,7 L e 154,3 L frente aos 152 L observados, correspondendo a erro relativo inferior a 2%. Esse resultado é consistente com o fato de esse sabor possuir o maior histórico de vendas entre os analisados. Para os demais sabores, caracterizados por baixos volumes mensais de venda, as previsões apresentaram maior discrepância em relação aos valores observados. Destaca-se o caso do Abacaxi, cuja demanda caiu para apenas 3 L em junho de 2026, enquanto a regressão linear e a LSTM estimaram 32,8 L e 13,4 L, respectivamente. Como essa redução não possui precedentes na série histórica, ambos os modelos tenderam a reproduzir o comportamento médio observado nos meses anteriores. De forma geral, a LSTM apresentou comportamento mais conservador, prevendo volume igual a zero para seis dos nove sabores avaliados. A regressão linear, por sua vez, produziu estimativas distintas de zero para todos os sabores, refletindo maior sensibilidade às diferenças de demanda entre os produtos.

3.5. Estratégias de Gestão de Estoque

Como a regressão linear apresentou desempenho superior na comparação entre os modelos, suas previsões foram utilizadas para definir três estratégias de planejamento de estoque: Conservadora, Equilíbrio e Otimista. A faixa de incerteza foi estimada com base no erro histórico de previsão de cada sabor, obtido por validação cruzada leave-one-out (LOOCV), na qual cada observação mensal é utilizada, sucessivamente, como conjunto de teste e as demais como conjunto de treinamento. O desvio-padrão dos erros resultantes (Tabela 4) foi adotado como medida da incerteza associada às previsões. A partir dessas margens, definem-se as três estratégias operacionais para um dado sabor i e período t:

$$\textit{Conservadora}_i(t) = max(0, \hat{y}_i(t) - \sigma_i).$$

$$\textit{Equilíbrio}_i(t) = \hat{y}_i(t).$$

$$\textit{Otimista}_i(t) = \hat{y}_i(t) + \sigma_i.$$

em que $\hat{y}_i(t)$ representa a previsão pontual do modelo para o sabor i no período t, e σ_i corresponde ao desvio-padrão do erro obtido por validação cruzada. A Tabela 5 apresenta a aplicação dessas estratégias às previsões para junho de 2026.

Tabela 4. Erro de previsão por sabor via validação cruzada *leave-one-out*

Sabor	MAE (L)	Desvio-padrão do erro (L)
Abacaxi	18,9	23,7
Abacaxi com Hortelã	4,0	5,6
Bergamota	3,4	3,9
Laranja	44,9	49,6
Laranja e Couve	2,3	2,8
Limonada	12,1	14,4
Maracujá	2,9	4,2
Morango	9,9	12,9
Uva	6,6	7,6

Para o sabor Laranja, o valor observado (152 L) situou-se dentro do intervalo definido pelas estratégias Conservadora (103,1 L) e Otimista (202,3 L), enquanto a Estratégia de Equilíbrio praticamente coincidiu com o valor real (152,7 L). Esse resultado era esperado, uma vez que esse sabor dispõe do maior histórico de dados para treinamento.

Nos sabores de menor volume, cinco dos oito valores observados permaneceram dentro da faixa delimitada pelas estratégias Conservadora e Otimista, mesmo quando a previsão pontual apresentou erro significativo. A principal exceção foi o sabor Abacaxi, cuja queda abrupta de demanda não pôde ser antecipada pelo modelo, fazendo com que até mesmo a Estratégia Conservadora superestimasse o volume efetivamente vendido.

As três estratégias representam diferentes níveis de tolerância ao risco no planejamento de estoque. A Estratégia Conservadora prioriza a redução de desperdícios de

Tabela 5. Estratégias de estoque para junho de 2026, com base na Tabela 3

Sabor	Real (L)	Conservadora (L)	Equilíbrio (L)	Otimista (L)
Abacaxi	3,0	9,1	32,8	56,5
Abacaxi com Hortelã	0,0	0,0	1,4	7,0
Bergamota	7,0	0,0	0,7	4,6
Laranja	152,0	103,1	152,7	202,3
Laranja e Couve	0,0	0,0	0,5	3,3
Limonada	4,0	0,0	2,6	17,0
Maracujá	12,0	0,0	0,7	4,9
Morango	9,0	0,0	2,1	15,0
Uva	5,0	0,0	1,9	9,5

insumos perecíveis, enquanto a Estratégia Otimista busca minimizar o risco de ruptura de estoque por meio de maior disponibilidade de produtos. A Estratégia de Equilíbrio corresponde à previsão pontual do modelo e é indicada para o planejamento operacional em condições normais, podendo as demais estratégias ser utilizadas como limites inferior e superior de produção, conforme a política de gestão de riscos da empresa. Considerando que a empresa adota uma estratégia de demanda puxada, a Estratégia Conservadora mostra-se a mais compatível com seu contexto operacional.

Os resultados obtidos mostram que a complexidade do modelo não implica necessariamente melhor desempenho preditivo. Embora a LSTM seja capaz de representar relações temporais mais complexas, seu desempenho foi limitado pela pequena quantidade de dados disponível para cada sabor. Em contrapartida, a regressão linear apresentou maior capacidade de generalização, corroborando os achados de [Golabek et al. 2020] para produtos do setor de bebidas e reforçando a importância de selecionar modelos compatíveis com o volume e as características dos dados disponíveis.

4. Considerações Finais

Este trabalho desenvolveu e avaliou dois modelos de previsão de demanda regressão linear e rede neural recorrente do tipo Long Short-Term Memory (LSTM) aplicados ao planejamento da produção de uma empresa de sucos naturais. Os resultados demonstraram que, nas condições investigadas, a regressão linear apresentou desempenho superior ao da LSTM quando avaliada por sabor, evidenciando que modelos estatísticos mais simples podem ser mais adequados em cenários caracterizados por reduzido volume de dados históricos. Esse comportamento está de acordo com os resultados obtidos por Golabek et al. [Golabek et al. 2020], que também observaram desempenho competitivo de modelos lineares para previsão de demanda no setor de bebidas.

Além da comparação entre os modelos, um dos principais resultados deste estudo foi a identificação da limitação do coeficiente de determinação (R^2) quando calculado de forma agregada para produtos com escalas de vendas heterogêneas. Embora ambos os modelos tenham apresentado elevados valores de R^2 global, a avaliação individual por sabor revelou desempenho significativamente inferior em diversos casos, demonstrando que métricas agregadas podem mascarar limitações relevantes do modelo. Esse resultado reforça a importância de complementar avaliações globais com métricas desagregadas por unidade de análise, contribuindo para interpretações mais consistentes do desempenho

preditivo.

A principal limitação do estudo está relacionada ao reduzido volume de dados disponível. Dos quinze sabores comercializados pela empresa, apenas nove possuíam histórico suficiente para o treinamento dos modelos, resultando em séries com apenas nove a doze observações mensais por sabor. Essa limitação afetou principalmente o desempenho da LSTM, cuja capacidade de modelar relações temporais complexas depende de conjuntos de dados substancialmente maiores. Da mesma forma, sabores recentemente introduzidos no portfólio permaneceram fora da etapa de modelagem por não apresentarem histórico suficiente para treinamento.

No modelo de regressão linear, a análise dos coeficientes também evidenciou a presença de multicolinearidade entre as variáveis autorregressivas utilizadas, indicando oportunidades de aprimoramento por meio da seleção de variáveis ou da aplicação de técnicas de regularização. Além disso, a ocorrência de variações abruptas de demanda, como a observada para o sabor Abacaxi em junho de 2026, evidenciou que fatores operacionais e comerciais não contemplados pela base de dados podem exercer influência significativa sobre as vendas, reforçando a necessidade de complementar modelos quantitativos com informações do contexto operacional.

Como trabalhos futuros, destacam-se:

- Ampliação da base histórica de vendas, permitindo a inclusão dos sabores atualmente excluídos e o aprimoramento dos modelos preditivos;
- Investigação de modelos hierárquicos ou de efeitos mistos, capazes de compartilhar informações entre sabores com diferentes volumes de dados;
- Aplicação de técnicas de regularização, como Ridge e Lasso, para reduzir os efeitos da multicolinearidade observada na regressão linear;
- Desenvolvimento de modelos baseados no consumo de insumos, em substituição à modelagem centrada no produto final, visando aprimorar o planejamento de compras e estoques;
- Incorporação de variáveis operacionais, como disponibilidade de matéria-prima, promoções e eventos específicos, para explicar oscilações de demanda não capturadas pelas variáveis atualmente utilizadas.

Em síntese, os resultados indicam que a escolha do modelo preditivo deve considerar não apenas sua complexidade, mas também a quantidade e as características dos dados disponíveis. Para o cenário analisado, a regressão linear apresentou maior consistência e capacidade de generalização, constituindo uma alternativa mais adequada para apoiar o planejamento da produção. A medida que a base de dados da empresa for ampliada, torna-se pertinente reavaliar essa comparação com arquiteturas mais sofisticadas de aprendizado profundo, ampliando o potencial de utilização da inteligência artificial no suporte as decisões produtivas.

Referências

Dandaro, F. and Martello, L. L. (2015). Planejamento e controle de estoque nas organizações. *Revista Gestão Industrial*, 11(2).

Douaioui, K., Oucheikh, R., Benmoussa, O., and Mabrouki, C. (2024). Machine learning and deep learning models for demand forecasting in supply chain management: A critical review. *Applied System Innovation (ASI)*, 7(5).

Golabek, M., Senge, R., and Neumann, R. (2020). Demand forecasting using long short-term memory neural networks. *arXiv preprint arXiv:2008.08522*.

James, G., Witten, D., Hastie, T., Tibshirani, R., and Taylor, J. (2023). Statistical learning. In *An introduction to statistical learning: With applications in Python*, pages 15–67. Springer.

Montgomery, D. C., Peck, E. A., and Vining, G. G. (2021). *Introduction to linear regression analysis*. John Wiley & Sons.

Rocha, S. A. T. et al. (2024). A importância da gestão dos processos de produção na indústria alimentícia.

Rožanec, J. and Mladenic, D. (2021). Reframing demand forecasting: A two-fold approach for lumpy and intermittent demand. *arXiv preprint arXiv:2103.13812*.

Tošanović, N. and Štefanić, N. (2021). Evaluation of pull production control mechanisms by simulation. *Processes*, 10(1):5.

Veres, P. and Baráth, Z. (2024). Application of lstm model for forecasting production orders. *ADVANCED LOGISTIC SYSTEMS: THEORY AND PRACTICE*, 18(4):111–122.